Universidad de La Sabana

Entrega final · Grupo 8

Reconocimiento de señas aisladas de la Lengua de Señas Colombiana



Una BiGRU sobre landmarks de MediaPipe frente a una línea base clásica, evaluadas con señantes no vistos

Andrés Díaz, Lorena Valero, Jorge Anaya & Sabrina Miranda

Universidad de La Sabana · Octubre de 2026

Contexto y alcance



Universidad de La Sabana

Contexto

La lengua de la comunidad sorda del país; su aprendizaje formal sigue siendo limitado.

Tarea: señas aisladas

Cada video corto recibe una de 43 etiquetas: 33 de cortesía y los números del 1 al 10.

Generalización

Siempre habrá una persona nueva: se evalúa con señantes no vistos en el entrenamiento.

Fuera del alcance: lengua continua, traducción, campaña de colores (S1), tiempo real y despliegue sin validación previa con usuarios sordos.

Pregunta experimental

¿Un modelo secuencial sobre landmarks mejora el macro-F1 frente a una línea base clásica, y a qué costo computacional?

01

Hipótesis

La dinámica temporal del movimiento aporta información que los resúmenes estadísticos pierden.

02

Diseño de la comparación

Con solo 14 señantes de desarrollo no era obvio que se cumpliera: se diseñó para poder rechazarla.



Datos

LSC-54: 1.740 videos, 18 señantes, 43 señas



Universidad de La Sabana

Se trabaja con la campaña S2 (cortesía y números). S1 se excluye porque no garantiza que una misma persona no quede a ambos lados de la partición.

Procedencia y licencia

- Mora-Zarate, Garzón-Castro y Castellanos-Rivillas (2025), Data in Brief
- CC BY-NC 4.0: uso académico; los videos no se redistribuyen

1.740
videos únicos

43
clases

18
señantes

113.658
cuadros

Auditoría de calidad

- Pose detectada en el 99,5 % de los cuadros
- La mano más activa, solo en el 60 %
- El 32 % de los videos queda bajo 50 % de detección: se conservan
- Detección de 0,46 a 0,97 según la persona

Universidad de La Sabana

Se particiona por señante, nunca por video, para medir la generalización a personas nuevas

Desarrollo

14 señantes · 1.359 videos

Validación cruzada agrupada por señante: 7 folds de 192 a 206 videos.

Test bloqueado

4 señantes · 381 videos

Se evalúa una sola vez; la decisión se registró antes de tocar el test.

Medidas anti-fuga

- Pruebas: ningún señante en dos particiones
- Partición versionada y protegida
- Ajustes dentro de cada fold
- Hiperparámetros solo con desarrollo

Método

Universidad de La Sabana

Del video a 43 probabilidades

MediaPipe, normalización y una BiGRU con atención

Landmarks
MediaPipe Holistic: 7 puntos de pose y 21 por mano; sin rostro

Normalización
Pasan a píxeles, se centran en los hombros y se escalan

Ausencias
Las manos no detectadas quedan ausentes y esa información se conserva

Remuestreo
32 cuadros, vacíos de hasta 5 interpolados y 3 máscaras de presencia

BiGRU
Proyección 101→128 y dos capas bidireccionales de 128 unidades

Atención
Atención temporal y capa densa: 43 probabilidades

Preprocesamiento (común a ambos modelos)

Modelo secuencial

Modelos comparados

Universidad de La Sabana

Dos modelos con los mismos 7 folds, la misma semilla y el mismo preprocesamiento

Línea base

Regresión logística multinomial

- 493 variables por video: media, desviación, mínimo, máximo y velocidad
- Descarta el orden temporal
- C = 1 fijo; en sensibilidad (otros C, bosque aleatorio y SVM) el mejor llega a 0,554

21.242 parámetros · 0,9 s de ajuste

BiGRU base

Bidireccional, 2 capas × 128, con atención temporal

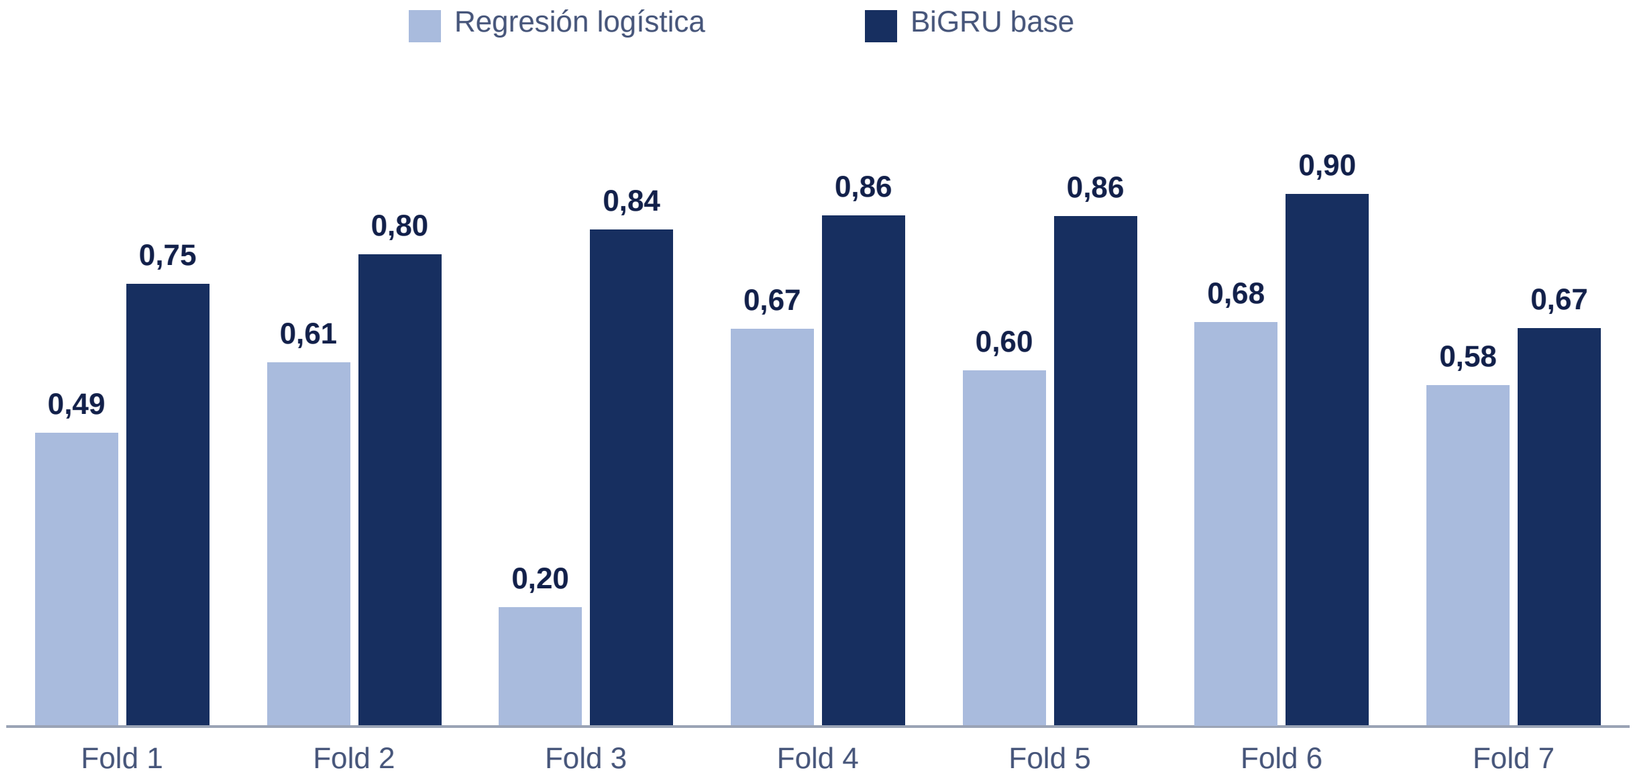
- AdamW, 80 épocas fijas; aumentos solo en entrenamiento
- Se reporta la última época, sin parada temprana
- Dropout 0,3 en la cabeza

552.023 parámetros · 227 s de ajuste

Regla de decisión fijada antes de ver resultados: mejora de macro-F1 ≥ 0,05 y en al menos 5 de 7 folds, con intervalo de confianza por remuestreo de señantes.

Validación cruzada por señante

En validación cruzada la BiGRU sube de 0,548 a 0,811 de macro-F1 y gana en los 7 folds



+0,263

diferencia promedio por fold; agrupada +0,244 (IC 95 %: +0,16 a +0,37)

7 de 7

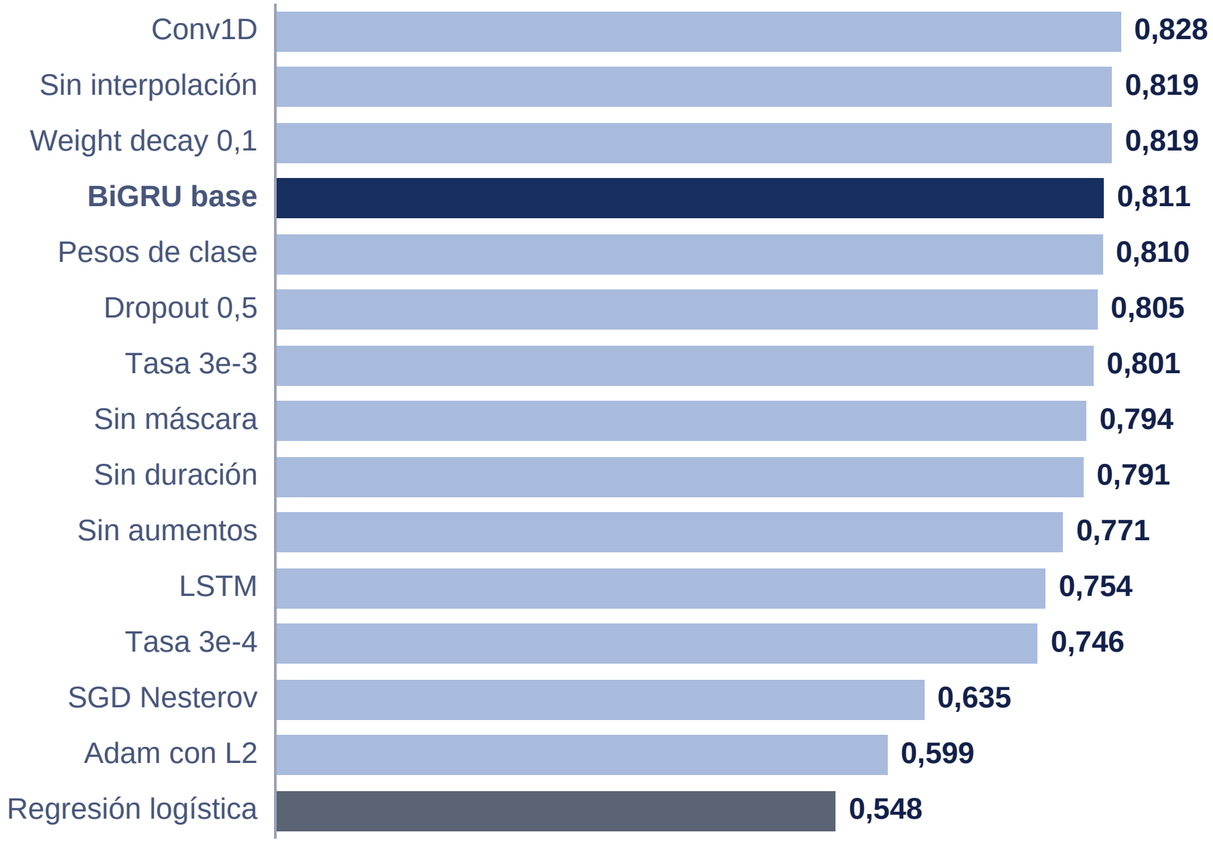
folds en los que la BiGRU supera a la línea base

0,527

peor señante con la BiGRU (0,108 con la línea base)

Universidad de La Sabana

Aumentos, máscara y duración aportan; ninguna variante supera a la base



Optimizador: AdamW 0,811; SGD 0,635; Adam con L2 0,599. Con la tasa sin reajustar, Adam y SGD subajustan.

Aumentos: aportan ≈ 0,04 (0,771 sin ellos).

GRU frente a LSTM: 0,811 frente a 0,754, con 23 % menos parámetros.

Mejoras menores: tres variantes superan la base por menos de 0,02 (IC con cero); la Conv1D empata: la ganancia viene de modelar la secuencia.

Universidad de La Sabana

Test bloqueado

0,881

macro-F1 de la BiGRU en 4 señantes no vistos

frente a 0,685 de la línea base (+0,196)

En el test, la BiGRU confirma la dirección y el tamaño del efecto observados

Exactitud	0,669 →	**0,869**
Top-3	0,829 →	**0,955**
Parámetros	21.242 →	**552.023**
Tiempo de ajuste	0,9 s →	**227 s**

Latencia de 6,8 ms por video individual en CPU: compatible con una herramienta de práctica interactiva.

Variación entre personas

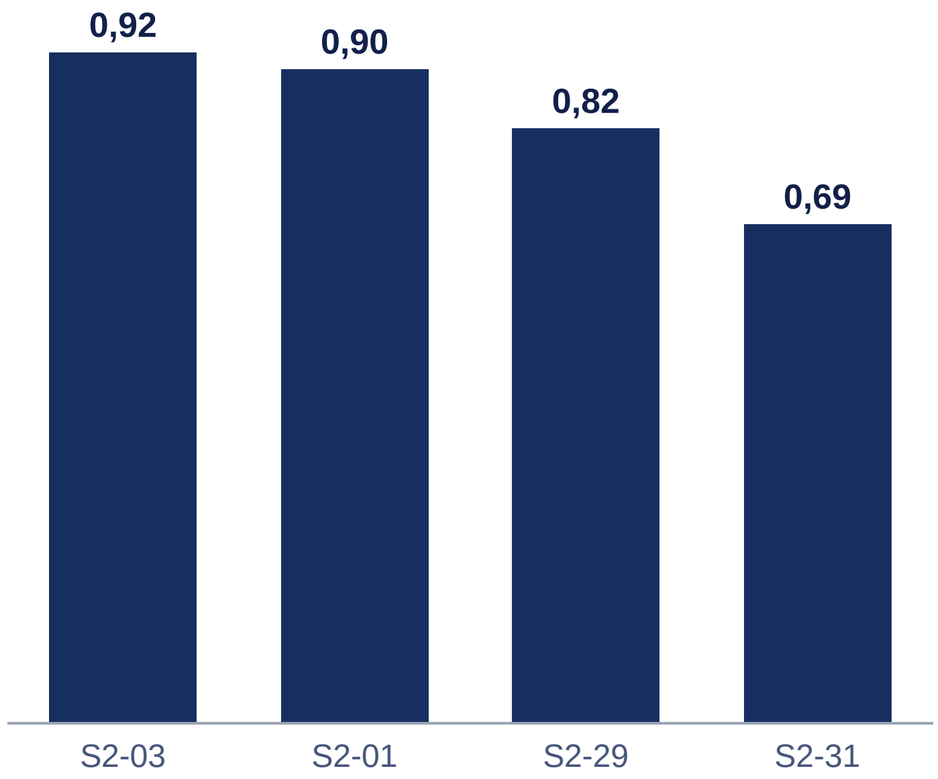
El desempeño depende de la persona: de 0,69 a 0,92 de macro-F1 en el test

01 **El test es algo optimista:** la detección de manos es mayor en test (0,73) que en desarrollo (0,57).

02 **S2-31 concentra 19 de los 50 errores** con solo 61 videos: falla el 31 % de los suyos.

03 **Con 4 señantes el intervalo es amplio;** la mejor referencia de variación es la CV: 0,811 ± 0,079.

Macro-F1 de la BiGRU por señante de test



Análisis de errores

Los errores se concentran en los números contiguos, con seis → uno a la cabeza

Hipótesis, no probada

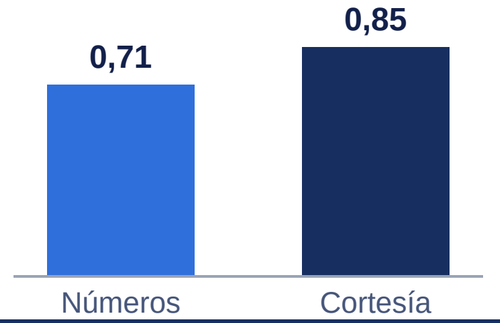
Los números difieren en la configuración de los dedos, un detalle que 21 puntos 2D por mano capturan mal; usar z o ángulos entre dedos sería la prueba natural.

Calibración: ECE de 0,114. El modelo es sobreconfiado y debe recalibrarse antes de usar un umbral de abstención.

Confusiones más frecuentes

seis → uno	6
cuatro → tres	3
bien → por favor	3
nueve → ocho	2
ocho → siete	2

F1 medio en validación cruzada



50 de 381

videos mal clasificados (13 %)

10 de 43

clases con F1 = 1,0

Limitaciones

Cuatro limitaciones acotan las conclusiones

Alcance léxico

43 señas aisladas de una sola campaña: reconocer vocabulario aislado no equivale a comprender la lengua.

01

Incertidumbre estadística

22 clases se validan con un único señante por fold y el test, con 4 señantes, deja intervalos amplios.

02

Representatividad

18 señantes sin metadatos demográficos: no se sabe si son sordos, oyentes o intérpretes.

03

Alcance de la comparación

Línea base ajustada en el análisis de sensibilidad (mejor: 0,554); no se probó gradient boosting; la licencia CC BY-NC impide el uso comercial.

04



Recomendaciones de uso

Apto para practicar, no para traducir

Antes de cualquier uso real: validación con la comunidad sorda y con docentes de LSC, más datos de más personas y un umbral de confianza, tras recalibrar, para abstenerse.

Uso previsto

- Practicar vocabulario básico de LSC (cortesía y números)
- Mostrar las tres señas más probables (top-3 = 0,955), no una sola respuesta
- Avisar al usuario cuando la detección de manos sea baja

Usos no previstos

- Traductor o sustituto de intérpretes
- Evaluar o calificar a personas
- Reconocimiento de lengua continua
- Vigilancia o uso comercial

Trabajo futuro

Cinco mejoras, en orden de retorno esperado

1 **Más señantes y condiciones de captura,** la causa raíz de la brecha entre entrenamiento y validación.

2 **Rasgos de forma de la mano** (profundidad z, ángulos entre dedos) para separar los números contiguos.

3 Conjunto de Conv1D y BiGRU: la Conv1D empata con la base (+0,019, IC con cero) y sus errores podrían ser complementarios.

4 **Manejo explícito de la baja detección:** abstenerse o pedir que se repita la seña.

5 **Recalibración (ECE 0,114)** para sustentar el umbral de abstención.



Conclusiones

La hipótesis se acepta, con matices

+0,26

de macro-F1 en validación cruzada (7 de 7 folds) y +0,20 en el test bloqueado.

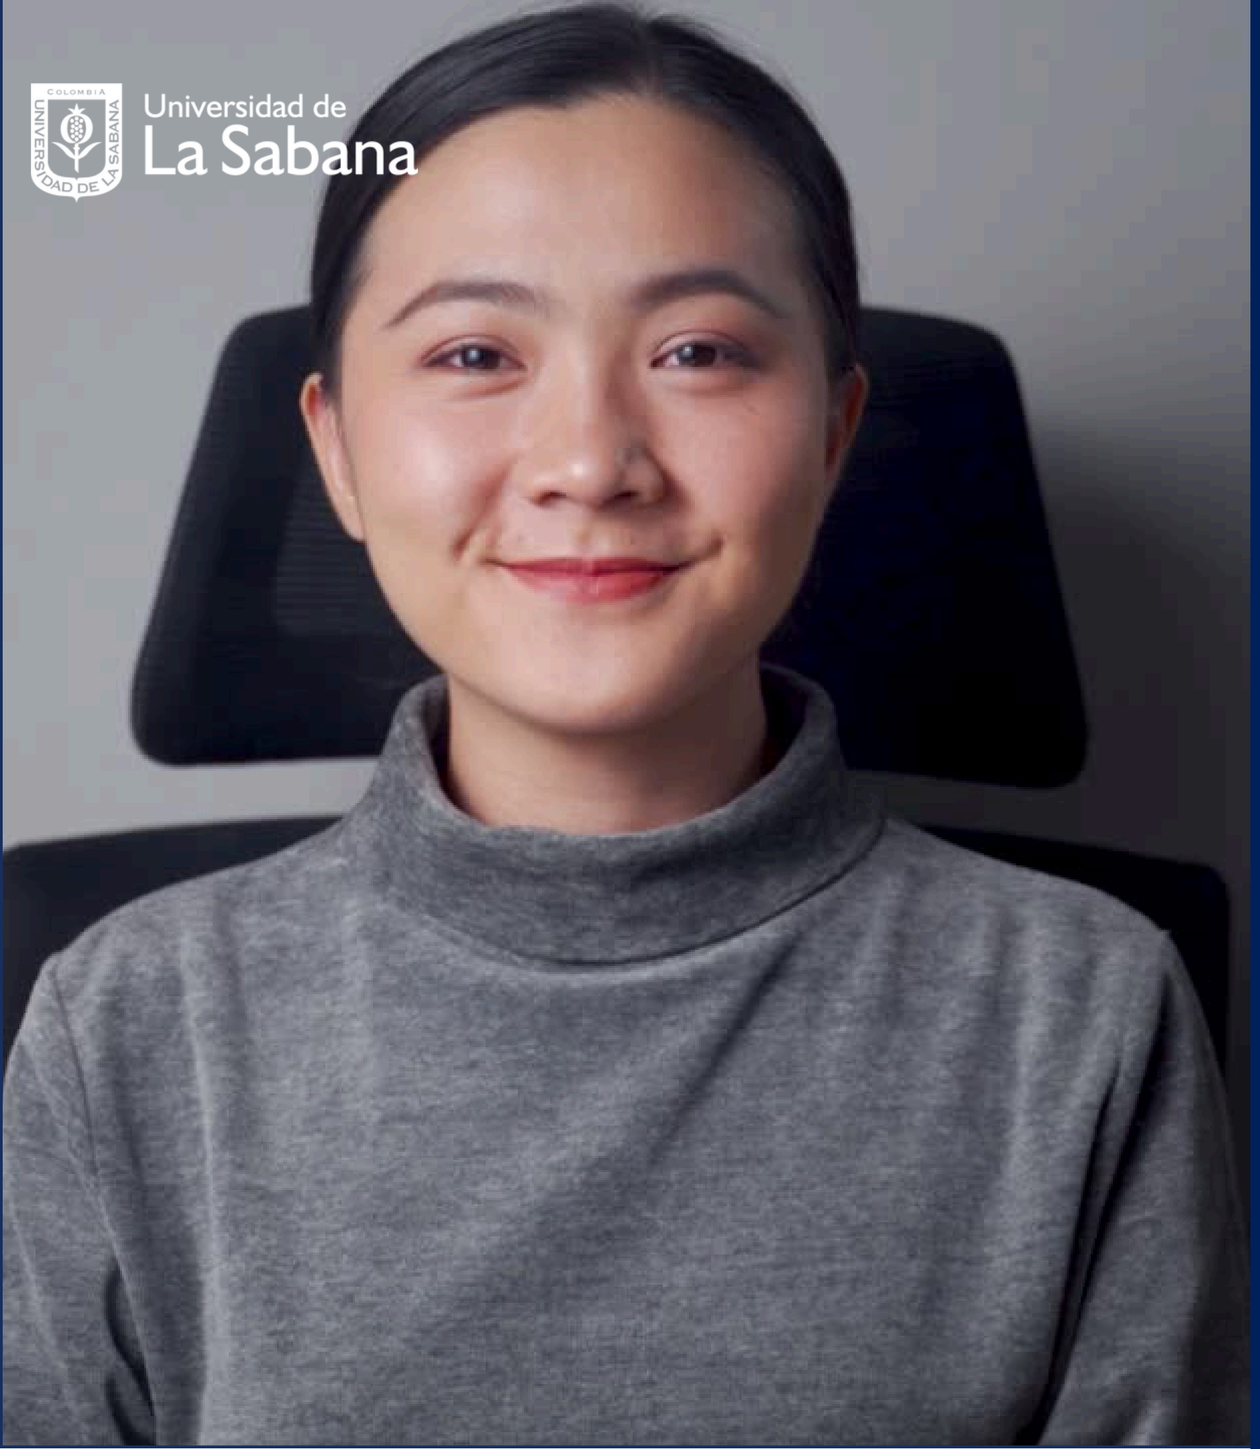
≈250×

más tiempo de entrenamiento, pero 6,8 ms de inferencia por video: compatible con uso interactivo.

0,69 a 0,92

de macro-F1 por señante en test: la ganancia es robusta, pero su magnitud depende de la persona y de la detección.

El modelo es sobreconfiado y 18 señantes no permiten generalizar más allá de este grupo.



Gracias

Repositorio

github.com/andresdila/Isc54-reconocimiento-senas

Reproducibilidad

Semilla 2026 y 22 pruebas automáticas, incluida la anti-fuga

Referencias

[1] Mora-Zarate, J. E., Garzón-Castro, C. L. y Castellanos-Rivillas, J. A. (2025). LSC-54: A landmark-based dataset for Colombian Sign Language. Data in Brief, 63, 112145. https://doi.org/10.1016/j.dib.2025.112145
[2] Lugaresi, C., et al. (2019). MediaPipe: A framework for building perception pipelines. arXiv:1906.08172.
[3] Scikit-learn Developers. (s. f.). Common pitfalls and recommended practices. https://scikit-learn.org/stable/common_pitfalls.html
[4] Cho, K., et al. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. arXiv:1406.1078.
[5] Loshchilov, I. y Hutter, F. (2019). Decoupled weight decay regularization. ICLR.
[6] National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0). https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf